

logistic 回归

DTDT

2018 年 11 月 19 日

假设存在数据集 (x_i, y_i) , $x_i \in R^n$, $y_i \in \{0, 1\}$

令

$$P(Y = 1|x) = \frac{\exp(wx)}{1 + \exp(wx)}$$

$$P(Y = 0|x) = \frac{1}{1 + \exp(wx)}$$

如果将 p 看作发生概率, 则 $1 - p$ 就是不发生概率, $\frac{p}{1-p}$ 被称为几率, 对于 logistic 回归有:

$$\log \left(\frac{P(Y = 1|X)}{P(Y = 0|X)} \right) = wx$$

logistic 回归就是要求得 w 矩阵, 下面用极大似然估计求 w

模型的似然函数为:

$$\prod_{i=1}^n \pi(x_i)^{y_i} (1 - \pi(x_i))^{1-y_i}$$

其中

$$\pi(x) = P(Y = 1|x) = \frac{\exp(wx)}{1 + \exp(wx)}$$

对似然函数取 \log 有：

$$\begin{aligned} L(w) &= \sum_i^N y_i \log \pi(x_i) + (1 - y_i) \log(1 - \pi(x_i)) \\ &= \sum_i^N \left(y_i \log \frac{\pi(x_i)}{1 - \pi(x_i)} + \log(1 - \pi(x_i)) \right) \\ &= \sum_i^N (y_i(w \cdot x_i) - \log(1 + \exp(w \cdot x_i))) \quad (1) \end{aligned}$$

对 $L(w)$ 求极大值，下面证明 $L(w)$ 是凸的

(1) 式第一部分是凸的，第二部分假设

$$\begin{aligned} f(x) &= -\log(1 + \exp(w \cdot x_i)) \\ f'(x) &= -\frac{\exp(x)}{1 + \exp(x)} \\ f''(x) &= \frac{\exp(x)}{(1 + \exp(x))^2} \quad (2) \end{aligned}$$

(2) 式恒大于 0，所以 $f(x)$ 是个凸函数。且凸函数的非负线性组合还是凸函数，凸函数和仿射函数的复合是凸函数，因此 $L(w)$ 是凸函数。

对凸函数求解最优值问题有梯度下降法和牛顿法。

1. 牛顿法

函数的极值处偏导等于 0, 且凸函数最值等于极值, 因此最优化等价于求 $f'(x)$ 的零点。

$$\begin{aligned} w^{t+1} &= w^t - \left(\frac{\partial^2 L(w)}{\partial w \partial w^T} \right)^{-1} \frac{\partial L(w)}{\partial w} \quad (3) \\ \frac{\partial L(w)}{\partial w} &= \sum_i^N y_i x_i - \frac{x_i \exp(wx_i)}{1 + \exp(wx_i)} \\ \frac{\partial^2 L(w)}{\partial w \partial w^T} &= \sum_i^N x_i x_i^T \frac{\exp(wx_i)}{(1 + \exp(wx_i))^2} \\ &= x_i x_i^T P(Y = 1|x_i)P(Y = 0|x_i) \end{aligned}$$

2. 梯度下降法

由于是凸函数, 最后收敛的一定是最值。

$$w^{t+1} = w^t - \alpha \frac{\partial L(w)}{\partial w}$$

比较两种方法, 1 不需要设置超参数, 而且具有良好的收敛速度, 2 需要设置合适的 α , 收敛速度依赖于具体的 α 。看起来用方法 1 效果不错, 但实际中由于矩阵求逆时间复杂度太高, 因此大多用第二种方法。